SVEUČILIŠTE U SPLITU
FAKULTET ELEKTROTEHNIKE, STROJARSTVA I BRODOGRADNJE

ZAVRŠNI RAD

Primjena metoda strojnog učenja na MRI snimkama za predviđanje progresije Alzheimerove bolesti

Josip Bilić

Split, srpanj 2026.

SVEUČILIŠTE U SPLITU
FAKULTET ELEKTROTEHNIKE, STROJARSTVA I BRODOGRADNJE

Sveučilišni prijediplomski studij: **Računarstvo**
Smjer/Usmjerenje: **/**
Oznaka programa: 120
Akademska godina: 2025./2026.

Ime i prezime: **Josip Bilić**
JMBAG: 0171290426

ZADATAK ZAVRŠNOG RADA

Naslov: **PRIMJENA METODA STROJNOG UČENJA NA MRI SNIMKAMA ZA PREDVIĐANJE PROGRESIJE ALZHEIMEROVE BOLESTI**

Zadatak: Proučiti mogućnosti primjene metoda strojnoga učenja za predviđanje progresije Alzheimerove bolesti na temelju strukturnih MRI snimaka mozga i demografsko-kliničkih metapodataka iz skupa OASIS-2. Provesti odgovarajuću predobradu MRI snimaka te implementirati model temeljen na prijenosnom učenju uporabom 3D neuronske mreže MedicalNet ResNet-10. Evaluirati razvijeni model i usporediti njegovu uspješnost s modelom koji koristi isključivo metapodatke. Analizirati dobivene rezultate te raspraviti ograničenja i mogućnosti daljnjega razvoja predloženog pristupa.

Datum obrane: 15.07.2026.

Mentor:

Grujić Tamara

prof. dr. sc. Tamara Grujić

IZJAVA

Ovom izjavom potvrđujem da sam završni rad s naslovom PRIMJENA METODA STROJNOG UČENJA NA MRI SNIMKAMA ZA PREDVIĐANJE PROGRESIJE ALZHEIMEROVE BOLESTI pod mentorstvom prof. dr. sc. TAMARE GRUJIĆ pisao samostalno, primijenivši znanja i vještine stečene tijekom studiranja na Fakultetu elektrotehnike, strojarstva i brodogradnje, kao i metodologiju znanstveno-istraživačkog rada, te uz korištenje literature koja je navedena u radu. Spoznaje, stavove, zaključke, teorije i zakonitosti drugih autora koje sam izravno ili parafrazirajući naveo u završnom radu citirao sam i povezao s korištenim bibliografskim jedinicama.

Student



Josip Bilić

SADRŽAJ

1 UVOD ... 1
2 SKUP PODATAKA ... 3
2.1 Format MRI fotografija ... 4
2.2 Klinički metapodaci ... 4
3 PREDOBRADA PODATAKA ... 7
3.1 Ekstrakcija i organizacija ... 9
3.2 Pretvorba u NIfTI i reorijentacija ... 9
3.3 Korekcija bias polja ... 10
3.4 Uklanjanje lubanje ... 13
3.5 Prostorna registracija ... 15
3.6 Normalizacija intenziteta i rezanje ... 17
3.7 Usrednjavanje ... 18
4 IZRADA MODELA ... 20
4.1 Definicija zadatka ... 20
4.2 MedicalNet ... 21
4.3 Arhitektura modela ... 22
4.4 Postupak učenja i evaluacije ... 24
5 REZULTATI ... 26
5.1 Referentne vrijednosti ... 26
5.2 Usporedba modaliteta ... 26
5.3 Predviđanje pogoršanja ... 28
5.4 Predviđanje konverzije ... 30
5.5 Utjecaj anatomskog područja ... 31
6 ZAKLJUČAK ... 32
LITERATURA ... 34
POPIS OZNAKA I KRATICA ... 36
SAŽETAK ... 38
SUMMARY ... 39

1 UVOD

Alzheimerova bolest najčešći je uzrok demencije i jedan od najvećih zdravstvenih izazova starije populacije [1]. Riječ je o neurodegenerativnoj bolesti koja se razvija postupno, tijekom mnogo godina, pri čemu propadanje moždanoga tkiva nekad započinje znatno prije nego što se pojave prvi vidljivi klinički simptomi [2]. Upravo zbog te postupnosti od velike je važnosti rano i pouzdano prepoznavanje pacijenata kod kojih bolest napreduje, jer rana intervencija može usporiti tijek bolesti i osjetno poboljšati kvalitetu života oboljelih.

Magnetska rezonancija (engl. Magnetic Resonance Imaging, MRI) je neinvazivna pretraga koja omogućuje detaljan prikaz anatomije mozga te je stoga temeljni alat u istraživanju neurodegenerativnih bolesti. Strukturna MRI snimka mozga zapravo je trodimenzionalno polje brojeva u kojem svaki broj, nazvan voksel (trodimenzionalni piksel), opisuje jakost signala u jednoj maloj kocki tkiva. Suvremene metode dubokoga učenja, a osobito konvolucijske neuronske mreže (engl. Convolutional Neural Network, CNN), pokazale su se uspješnima u analizi ovakvih slikovnih podataka [3] i otvaraju mogućnost automatskoga prepoznavanja obrazaca povezanih s napredovanjem bolesti.

Glavna prepreka primjeni dubokoga učenja u medicinskoj slikovnoj dijagnostici jest ograničena količina podataka: prikupljanje i stručno označavanje MRI snimaka skupo je i sporo, pa su javno dostupni skupovi u pravilu premaleni za učenje velikih mreža od nule. Zbog toga se u ovome radu primjenjuje prijenosno učenje (engl. transfer learning), pri kojem se kreće od mreže prethodno naučene na velikoj zbirci medicinskih snimaka, a zatim se ona dodatno prilagođava dotičnom zadatku. Konkretno, kao polazište služe težine modela MedicalNet, odnosno trodimenzionalna mreža ResNet-10 prethodno naučena na velikoj zbirci 3D medicinskih snimaka [4].

Cilj je ovoga rada istražiti primjenu metoda strojnoga učenja za predviđanje progresije Alzheimerove bolesti na temelju MRI snimaka i pripadajućih metapodataka iz javno dostupnoga skupa podataka OASIS-2 [5].

Rad je, nakon uvodnog dijela, organiziran na sljedeći način. U drugome poglavlju opisan je skup podataka OASIS-2, format sirovih snimaka te pridruženi demografski i klinički metapodaci. Treće poglavlje detaljno opisuje cijeli cjevovod predobrade snimaka, pri čemu se za svaki korak objašnjava što radi i zašto je nužan. Četvrto poglavlje opisuje izradu modela strojnoga učenja nad tako pripremljenim podacima — definiciju zadatka, model MedicalNet, arhitekturu mreže te postupak učenja i evaluacije. Peto poglavlje donosi i analizira postignute rezultate, a šesto poglavlje sažima zaključke rada.

2 SKUP PODATAKA

Podaci korišteni u ovome radu potječu iz zbirke podataka OASIS-2 (engl. Open Access Series of Imaging Studies) [5] koja sadrži MRI snimke mozga. Zbirka je longitudinalna što znači da je svaki sudionik snimljen u više navrata, pri čemu su uzastopni posjeti razmaknuti najmanje godinu dana, što zbirku čini osobito prikladnom za proučavanje promjena mozga tijekom vremena. Sve su snimke prikupljene na jednome te istome uređaju, MR skeneru jakosti polja 1,5 T, primjenom identične MP-RAGE sekvence u sagitalnoj orijentaciji i pri rezoluciji voksela 1,0 × 1,0 × 1,25 mm. Time je uklonjena varijacija koja inače nastaje snimanjem na različitim uređajima, pa su razlike među snimkama prvenstveno posljedica stvarnih anatomskih razlika među sudionicima. Podatke je ustupio projekt OASIS (glavni istraživači: D. Marcus, R. Buckner, J. Csernansky i J. Morris; potpore P50 AG05681, P01 AG03991, P01 AG026276, R01 AG021910, P20 MH071616 i U24 RR021382) [5].

Kohortu pacijenata čini 150 starijih odraslih osoba u dobi od 60 do 96 godina, za koje je dostupno ukupno 373 slikovnih sesija. S obzirom na kognitivni status, sudionici se dijele u tri skupine. Najveću skupinu, 72 sudionika, čine osobe koje su tijekom cijeloga istraživanja ostale kognitivno stabilne. Drugu skupinu od 64 sudionika čine osobe koje su već pri prvome posjetu imale dijagnozu demencije i zadržale je do kraja, među kojima je 51 osoba s blagom do umjerenom Alzheimerovom bolešću. Treću, najmanju, ali za ovaj rad najzanimljiviju skupinu čini 14 sudionika koji su na početku bili bez demencije, a tijekom istraživanja iz zdravoga stanja prešli u dementno; upravo su to slučajevi progresije bolesti koji su u središtu interesa ovoga rada.

Tablica 2.1 Pregled kohorte

Obilježje	**Vrijednost**
Broj sudionika	150
Broj slikovnih sesija	373
Spol (Ž / M)	88 / 62
Posjeta po sudioniku	2 do 5 (najčešće 2)
Raspon dobi	60 – 96 godina

Bez demencije	72 sudionika (190 sesija)
S demencijom	64 sudionika (146 sesija), od toga 51 s Alzheimerovom bolešću
Konvertirani (progresija)	14 sudionika (37 sesija)
Rezolucija voksela	1,0 × 1,0 × 1,25 mm

2.1 Format MRI fotografija

Svaka MRI snimka u OASIS-2 skupu podataka pohranjena je kao volumetrijski zapis u Analyze 7.5 formatu, koji se sastoji od dvije datoteke: .hdr datoteke koja sadrži zaglavlje s metapodacima te .img datoteke koja sadrži sirove vrijednosti voksela. Ovakav format predstavlja binarnu reprezentaciju trodimenzionalnog volumena u kojem su podaci organizirani kao pravilna 3D mreža intenziteta.

Dimenzije pojedinačne snimke u ovom skupu iznose 128 × 256 × 256 voksela, pri čemu svaki voksel predstavlja intenzitet MRI signala u odgovarajućoj prostornoj lokaciji. Snimke su pohranjene bez eksplicitne informacije o prostornoj orijentaciji, što znači da Analyze format ne definira jednoznačno odnos osi volumena prema anatomskim smjerovima pacijenta (lijevo–desno, anteriorno–posteriorno, inferiorno–superiorno).

Podaci su organizirani hijerarhijski po direktorijima koji slijede OASIS konvenciju imenovanja oblika OAS2_<subjekt>_MR<posjet>, pri čemu svaki direktorij odgovara jednom subjektu i jednom posjetu. Unutar svakog direktorija nalaze se pojedinačne akvizicije iste MP-RAGE sekvence, koje su spremljene kao zasebne datoteke (npr. mpr-1, mpr-2 i slično), što omogućuje više uzastopnih snimanja iste anatomske strukture unutar istog posjeta.

2.2 Klinički metapodaci

Uz snimke zbirka pruža demografsku i kliničku tablicu koja za svaki posjet bilježi niz obilježja: dob, spol, broj godina obrazovanja (EDUC), socioekonomski status (SES), MMSE rezultat,

CDR ocjenu te nekoliko izvedenih volumetrijskih mjera — procijenjeni ukupni intrakranijalni volumen (eTIV), normalizirani volumen cijeloga mozga (nWBV) i atlasni faktor skaliranja (ASF).

Težina kognitivnoga oštećenja u zbirci se kvantificira dvjema standardnim kliničkim ljestvicama. Mini-Mental State Examination (MMSE) kratki je test kognitivnih sposobnosti s rezultatom u rasponu od 0 do 30, pri čemu niži rezultat upućuje na izraženije oštećenje [6]. Clinical Dementia Rating (CDR) ljestvica je težine demencije s vrijednostima 0 (bez demencije), 0,5 (vrlo blaga), 1 (blaga), 2 (umjerena) i 3 (teška demencija) [7]. Vrijednost CDR-a i njezina promjena između uzastopnih posjeta predstavljaju ključnu metriku za praćenje progresije.

Tablica 2.2 Glavna obilježja skupa

Obilježje	**Opis**
Age	Dob sudionika u godinama u trenutku posjeta
M/F	Spol sudionika
EDUC	Broj godina obrazovanja
SES	Socioekonomski status (ljestvica 1 – 5)
MMSE	Mini-Mental State Examination (0 – 30)
CDR	Clinical Dementia Rating (0; 0,5; 1; 2; 3)
eTIV	Procijenjeni ukupni intrakranijalni volumen (cm^3)
nWBV	Normalizirani volumen cijeloga mozga
ASF	Atlasni faktor skaliranja

Kako bi se stekao osjećaj za vrijednosti koje ta obilježja poprimaju, provedena je kratka opisna analiza nad svih 373 sesija. Prosječna dob sudionika u trenutku snimanja iznosi 77,0 godina, a sudionici su u prosjeku proveli 14,6 godina u obrazovanju, što kohortu opisuje kao stariju i razmjerno visoko obrazovanu. Vrijednosti MMSE-a u prosjeku su visoke (27,3 od mogućih 30), no s velikim rasponom (od 4 do 30), što odražava suživot kognitivno očuvanih i izrazito

oštećenih sudionika u istoj zbirci. Volumetrijske mjere ponašaju se očekivano: normalizirani volumen mozga (nWBV) kreće se oko 0,73 i opada s dobi i težinom demencije.

Tablica 2.3 Opisna statistika obilježja

Obilježje	**Sredina ± SD**	**Raspon (min – maks)**	**Nedostaje**
Dob (god.)	77,0 ± 7,6	60 – 98	0
Obrazovanje (god.)	14,6 ± 2,9	6 – 23	0
SES (1 – 5)	2,5 ± 1,1	1 – 5	19
MMSE (0 – 30)	27,3 ± 3,7	4 – 30	2
eTIV (cm^3)	1488 ± 176	1106 – 2004	0
nWBV	0,73 ± 0,04	0,64 – 0,84	0
ASF	1,20 ± 0,14	0,88 – 1,59	0

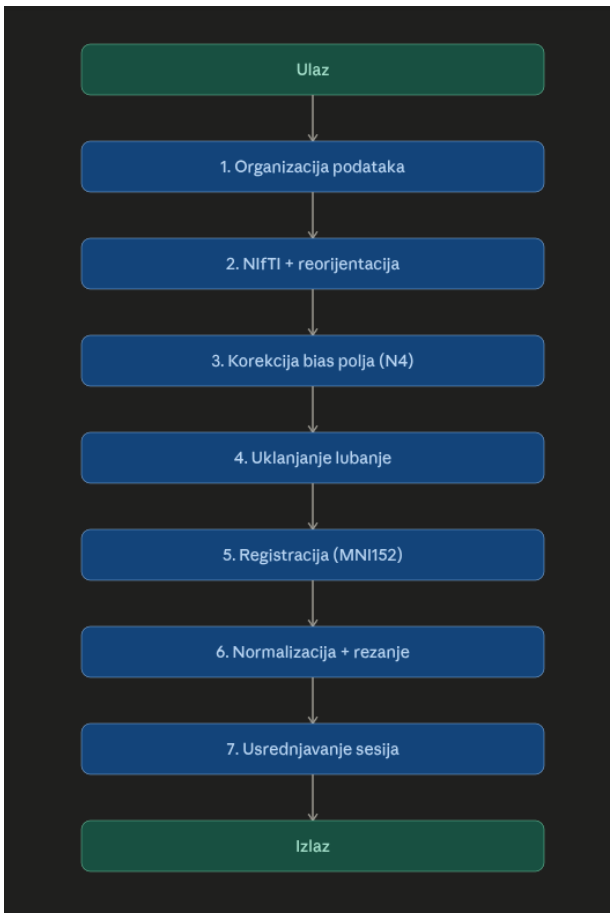
Posebno je važna raspodjela CDR ocjene jer ona predstavlja ciljnu informaciju. Od ukupno 373 sesije, njih 206 ima CDR 0 (bez demencije), 123 sesije imaju CDR 0,5 (vrlo blaga demencija), 41 sesija CDR 1 (blaga) te 3 sesije CDR 2 (umjerena demencija); ocjena CDR 3 ne pojavljuje se u zbirci. Takva je raspodjela izrazito neuravnotežena i pomaknuta prema nižim ocjenama, a broj prijelaza u teže stanje (slučajeva progresije) malen je, što je ograničenje s kojim se model mora nositi i na koje se vraća u petome poglavlju.

U ovome se radu opisani metapodaci koriste kao zaseban, tablični izvor informacija koji se na razini modela spaja sa slikovnim značajkama izlučenim iz MRI snimaka, o čemu je riječ u četvrtome poglavlju.

3 PREDOBRADA PODATAKA

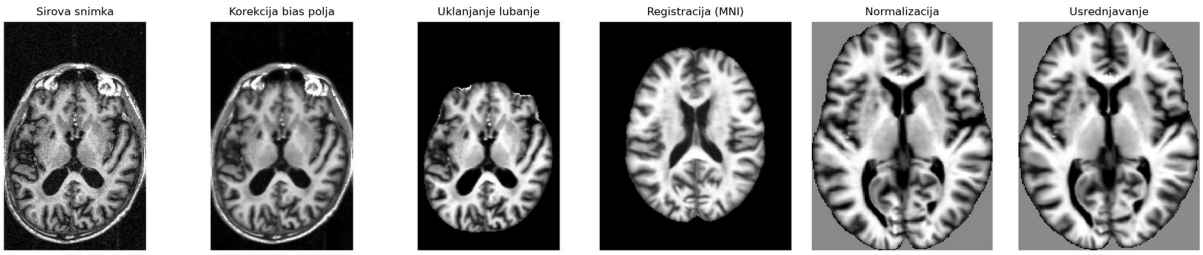
Sirove MRI snimke, predstavljene u prethodnom poglavlju, u svom izvornom obliku nisu prikladne za izravnu analizu putem modela. Premda potječu s istoga uređaja i iste sekvence, snimke se međusobno razlikuju po nizu obilježja koja nemaju veze s anatomijom mozga. Pohranjene su u zastarjelome formatu, nisu jasne orijentacije, glava se u svakoj snimci nalazi na nešto drukčijem položaju i pod drukčijim kutom, svaka snimka uz mozak sadrži i lubanju, kosu, oči i vrat, a apsolutne su vrijednosti svjetline proizvoljne jer magnetska rezonancija nije kvantitativna metoda. Zadaća je predobrade ukloniti tu suvišnu varijaciju kako bi se snimke koje se predaju modelu razlikovale prvenstveno po onome što se zapravo želi proučavati — po anatomiji mozga. Drugim riječima, cilj je postići da voksel na položaju (i, j, k) u svakoj snimci označava istu anatomsku lokaciju, mjerenu na istoj skali. Ako se te smetajuće razlike ostave u podacima, model možda uoči neke slučajne korelacije, npr. da osobe s natprosječno velikim nosom spadaju u skupinu visokog rizika, i zbog toga počne donositi pogrešne zaključke.

Predobrada je u ovome radu organizirana kao slijed od sedam koraka, pri čemu svaki obavlja određenu operaciju, čita stablo direktorija sa snimkama i svoj rezultat upisuje u novo, zrcalno stablo. Takvo spremanje svakoga međurezultata na disk donosi tri praktične koristi: postupak se može prekinuti i nastaviti u bilo kojem koraku, svaka se međusnimka može vizualno pregledati, a automatizirana rutina kontrole kvalitete (engl. Quality Control, QC) može provjeriti izlaz svakoga koraka prije nego što ga sljedeći iskoristi. Sedam je koraka redom: ekstrakcija i organizacija podataka, pretvorba u NIfTI format uz reorijentaciju, korekcija bias polja, uklanjanje lubanje, prostorna registracija na standardni predložak, normalizacija intenziteta s rezanjem te usrednjavanje sesija. Cjelokupni je tijek prikazan na slici 3.1, a zajednička logika obilaska direktorija, obrade po snimci, preskakanja već obrađenih mapa i oslobađanja memorije izdvojena je u pomoćni modul kako se ne bi ponavljala u svakom koraku.



Slika 3.1 Potpuni cjevovod

Slika 3.2 sažima učinak cijeloga cjevovoda na jednom te istom aksijalnom presjeku, prateći kako se ista snimka mijenja korak po korak — od sirove snimke, preko korekcije bias polja i uklanjanja lubanje, do registracije u standardni prostor i konačne normalizacije intenziteta.



Slika 3.2 Usporedba istog presjeka subjekta

3.1 Ekstrakcija i organizacija

Prije bilo kakve obrade samih slika sirovi skup podataka se mora dovesti u jedinstven i predvidljiv raspored. Ovaj korak ne provodi nikakvo računanje nad snimkama; jedina mu je svrha osigurati da se svaki kasniji korak može osloniti na isti jednostavni dogovor — jedan korijenski direktorij koji sadrži po jednu mapu za svaku sesiju, pri čemu svaka mapa izravno sadrži datoteke snimaka. Korak je potreban zato što skup OASIS-2 ne dolazi u tom obliku: preuzima se u nekoliko zasebnih dijelova, a unutar svake je sesije stvarna snimka zakopana u pomoćnim poddirektorijima, okružena izvedenim datotekama koje za ovaj rad nisu potrebne.

Organizaciju obavljaju tri kratke funkcije koje se izvode redom. Prva spaja zasebno preuzete dijelove arhiva u jedan zajednički direktorij, tako da sve sesije stoje jedna pokraj druge. Druga zatim prolazi kroz svaku sesiju i zadržava samo mapu sa sirovim snimkama, odbacujući unaprijed izračunate proizvode koji ovdje samo zauzimaju prostor. Treća naposljetku izravnava preostali poddirektorij premještanjem njegovih datoteka izravno u mapu sesije. Krajnji je rezultat stablo direktorija imenovano po OASIS konvenciji, na kojem počivaju svi kasniji koraci. Budući da je riječ isključivo o premještanju i brisanju datoteka, kontrola se kvalitete ovdje svodi na provjeru da je nakon konsolidacije broj sesija ostao nepromijenjen i da svaka mapa sadrži očekivane snimke.

3.2 Pretvorba u NIfTI i reorijentacija

Ovaj korak pretvara svaku snimku iz zastarjeloga formata Analyze 7.5 u format NIfTI (.nii.gz) i u istom prolazu prepisuje podatke tako da osi voksela pokazuju u nepromjenjivom, standardnom anatomskom smjeru. NIfTI je danas de facto standardni format u neuroslikanju, a ključna mu je prednost pred Analyzeom to što uz vokselske vrijednosti pohranjuje i eksplicitnu afinu matricu — transformaciju veličine 4×4 koja preslikava indeks voksela (i, j, k) u stvarni fizički položaj (x, y, z) izražen u milimetrima. Upravo ta matrica omogućuje da se kasnije uopće može govoriti o udaljenostima, orijentacijama i poravnanju u fizički smislenim jedinicama, a o njoj ovisi svaka geometrijska operacija u nastavku cjevovoda.

Korak istodobno rješava dva odvojena problema. Prvi je sam format: ostavljanje podataka u zastarjelom i prostorno dvosmislenom zapisu otvara vrata tihim pogreškama, dok je NIfTI podržan svim alatima koji se kasnije koriste. Drugi je, suptilniji, orijentacija. Kako je već

istaknuto, Analyze ne bilježi nedvosmisleno na koju stranu pokazuju osi snimke, pa dvije snimke mogu sadržavati isti mozak, ali s drukčije poredanim ili zrcaljenim osima. Ako se to ne ujednači, zamjena lijeve i desne strane u jednoj snimci u odnosu na drugu postaje za model nerazlučiva od stvarne anatomske asimetrije, što je u kliničkom kontekstu osobito opasna pogreška.

Reorijentacija se provodi funkcijom as_closest_canonical iz modula nibabel [8], koja svaku snimku dovodi u najbližu takozvanu RAS+ orijentaciju, u kojoj porast indeksa voksela pomiče prema pacijentovoj desnoj (Right), prednjoj (Anterior) i gornjoj (Superior) strani. Postoje i druge valjane konvencije koje koriste pojedini alati. Budući da sve postižu isti rezultat, bitno nije koja je odabrana, već da se jedna konvencija dosljedno primijeni na sve snimke. Funkcija pritom usklađeno transponira i zrcali i polje podataka i afinu matricu, pa snimka ostaje prostorno predvidive orijentacije. Svaka se snimka učitava, reorijentira, pretvara u 32-bitni zapis s pomičnim zarezom te sprema kao komprimirani NIfTI.

Pretvorba formata mjesto je na kojem se datoteke klasično mogu tiho izgubiti ili oštetiti, pa su nakon ovoga koraka provedene tri provjere. Najprije se uspoređuje broj izvornih i nastalih datoteka kako se ni jedna snimka ne bi usput izgubila, zatim se potvrđuje da oblik svake pretvorene snimke odgovara očekivanom ($128 \times 256 \times 256$) te se naposljetku prikazuju aksijalni presjeci uzorka snimaka kako bi se okom uočio bilo kakav grub neuspjeh pretvorbe. Reprezentativna sirova snimka u trima ortogonalnim presjecima već je prikazana u prethodnome potpoglavlju (Slika 3.2).

3.3 Korekcija bias polja

U idealnoj bi MRI snimci jedna te ista vrsta tkiva — primjerice siva tvar — imala jednak intenzitet u cijelome mozgu. U praksi to nije tako. Nesavršenosti radiofrekvencijskih zavojnica te način na koji magnetsko polje međudjeluje s tkivom nameću snimci glatko, sporo promjenjivo sjenčanje koje jedne dijelove posvjetljuje, a druge potamnjuje. To se sjenčanje naziva bias poljem ili nehomogenošću intenziteta: niskofrekventno je i mijenja se postupno preko centimetara. Bias polje smeta iz dvaju razloga. Prvo, narušava pretpostavku da je intenzitet pouzdan pokazatelj vrste tkiva. Drugo, loše se slaže s kasnijom normalizacijom intenziteta — ako se standardizira snimka koja još nosi jak gradijent sjenčanja, taj gradijent iskrivljuje cijelu normalizaciju. Zbog toga se bias polje uklanja prije normalizacije.

Klasična je metoda za ovaj problem N3 (engl. nonparametric nonuniform intensity normalization) [9], koja polje procjenjuje iterativnim izoštravanjem histograma intenziteta. U ovome se radu koristi njezino suvremeno i široko prihvaćeno poboljšanje N4 [10]: ono zamjenjuje N3 model polja fleksibilnijom prilagodbom B-zljebovima (engl. B-spline) i koristi bržu višerezolucijsku optimizaciju, čime postaje robusnije i točnije. N4 je postao zadanim izborom u većini cjevovoda jer ne zahtijeva model tkiva, neovisan je o kontrastu i ima slobodno dostupnu, dobro provjerenu implementaciju; ovdje je upotrijebljena ona iz modula SimpleITK [11]. Postoje i alternativni pristupi (primjerice korekcija ugrađena u FSL ili FreeSurfer), no oni su uže vezani uz vlastite cjevovode, dok je N4 samostalan i lako uklopiv u proizvoljan slijed koraka.

Obrada svake snimke teče sljedećim slijedom. Snimka se najprije reorijentira (na RAS) kako bi sve snimke dijelile istu semantiku osi. Prije procjene polja snimka se odšumljuje gradijentnom anizotropnom difuzijom. Ona zaglađuje snimku unutar homogenih područja, a istodobno čuva rubove. Odšumljivanje je konfigurirano vremenskim korakom 0,04 i deset iteracija, što je dovoljno za potiskivanje šuma bez znatnog gubitka oštrine granica.

Prije nego što algoritam uopće počne procjenjivati bias polje, mora znati gdje se u snimci nalazi tkivo. Bias polje opisuje kako se mijenja svjetlina tkiva, pa ga ima smisla računati samo unutar glave, a ne i u tamnoj pozadini oko nje, gdje nema nikakvoga signala korisnog za ovaj rad. Kad bi se u procjenu uključila i pozadina, ona bi unijela pogrešku i iskrivila procijenjeno polje. Zbog toga se iz snimke najprije izdvaja maska — binarna oznaka koja jednostavno kaže koji vokseli pripadaju glavi, a koji pozadini.

Ta se maska dobiva pragiranjem: svi vokseli svjetliji od neke granične vrijednosti proglašavaju se tkivom, a oni tamniji pozadinom. Kako bi se izbjeglo ručno pogađanje te granice za svaku snimku posebno, ona se određuje automatski, Li metodom (engl. Li thresholding) [12], koja iz raspodjele intenziteta sama pronalazi prag koji najbolje razdvaja tkivo od pozadine. Tako dobivena maska zna imati sitne rupe (primjerice ondje gdje su pojedini vokseli unutar glave slučajno tamni), pa se dodatno „zagladi" morfološkim zatvaranjem — postupkom koji

popunjava male praznine i spaja rubove — čime maska postaje kompaktno, cjelovito područje glave.

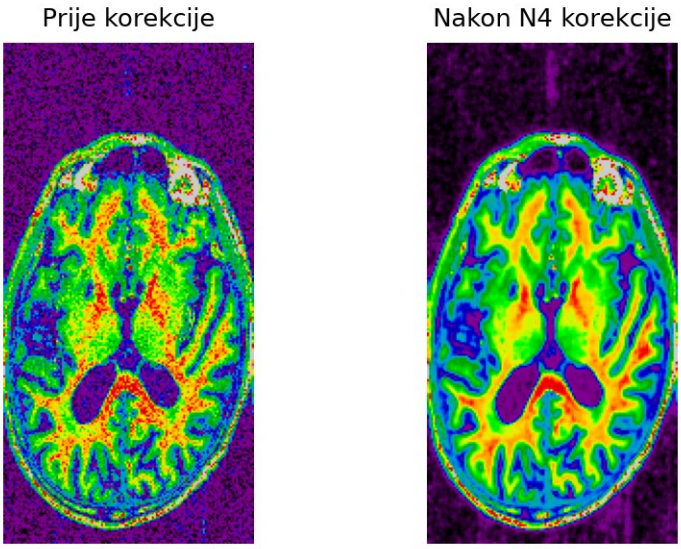
Bias polje je glatko i mijenja se vrlo sporo preko snimke, bez naglih skokova i sitnih detalja. To znači da ga ne treba računati na svakom pojedinom vokselu pune snimke — jednako se dobro može opisati i na grubljoj manje detaljnoj snimci, što donosi veliku vremensku uštedu. Zato se snimka prije procjene smanji za faktor dva u svakoj dimenziji; na toj manjoj snimci procjena polja traje znatno kraće, a ništa se ne gubi jer polje ionako nema finih detalja koje bi gruba rešetka mogla zanemariti.

Naravno, sama snimka koju želimo ispraviti ostaje u punoj rezoluciji. Zato se procijenjeno polje na kraju ponovno preslika natrag na izvornu, punu rešetku, a ispravljena snimka dobiva se tako da se polazna snimka podijeli tim poljem (čime se ukloni sjenčanje). Drugim riječima: polje se procjenjuje na nižoj rezoluciji, ali se primjenjuje na punoj. Ovo je običajen kompromis N4 metode kojim se dobiva na brzini bez velikog gubitka na kvaliteti.

Da bi N4 metoda uklonila neravnomjernu osvijetljenost snimke, mora je najprije što točnije opisati. Najlakše ju je zamisliti kao sjenu razlivenu preko snimke koja je jedne dijelove posvijetlila, a druge potamnila. Kad se ta sjena precizno mapira, ispravak je jednostavan.

N4 tu sjenu ne pogađa odjednom, nego postupno, od grube prema sitnoj. U prvom koraku metoda uhvati samo najkrupniju neravnomjernost, primjerice to da je jedna strana snimke općenito svjetlija od druge. U svakom sljedećem koraku opisuje sve sitnije nepravilnosti. Koliko će se truda uložiti u pojedini korak određuje broj iteracija.

U ovome je radu metoda radila u četiri takva koraka, s najviše 50, 50, 30 i 20 pokušaja (redom od najgrubljega prema najsitnijem); ako se ispravak ustali i prije toga, korak završava ranije. Više pokušaja na početku ima smisla jer se ondje određuje glavnina sjene, dok na kraju treba tek malo fine dorade.



Slika 3.3 Učinak N4 korekcije bias polja na aksijalnom presjeku, prikazan paletom boja nipy_spectral

Kako je bias polje multiplikativno, njegovo bi uklanjanje trebalo smanjiti rasap intenziteta jednoga tkiva u odnosu na njegovu srednju vrijednost. Taj se rasap mjeri koeficijentom varijacije (CV), omjerom standardne devijacije i srednje vrijednosti voksela unutar maske. Kontrola kvalitete za svaku snimku računa CV prije i nakon korekcije te rezultate postupno upisuje u datoteku, čime je izvođenje inkrementalno i otporno na prekide. Nad zabilježenim snimkama srednji je koeficijent varijacije pao s približno 1,16 na približno 1,06, što potvrđuje dosljedno smanjenje rasapa intenziteta unutar tkiva. Valja iskreno napomenuti jednu ogradu: ova se provjera provodi prije uklanjanja lubanje, pa maska još uvijek obuhvaća lubanju i vlasište čiji intenziteti pokrivaju vrlo širok raspon; stoga su apsolutne vrijednosti CV-a visoke, a smislen je signal upravo njegovo dosljedno smanjenje, koje potvrđuju i vizualne usporedbe prije i nakon korekcije.

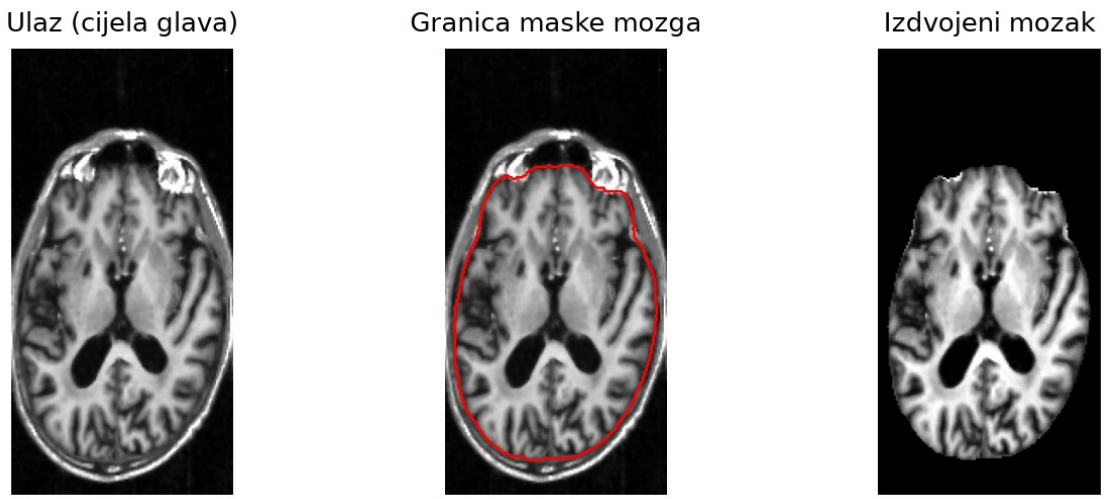
3.4 Uklanjanje lubanje

Uklanjanje lubanje (engl. skull stripping), odnosno ekstrakcija mozga, postupak je uklanjanja cijeloga ne-moždanoga tkiva iz snimke — lubanje, vlasišta, masti, mišića, očiju i vrata — tako da ostaje samo mozak s malim mozgom. Izlaz su dvije datoteke: snimka izdvojenoga mozga i binarna maska koja označava koji vokseli pripadaju mozgu. Za proučavanje moždane anatomije ovaj je korak važan jer je ne-moždano tkivo čista smetnja: debljina lubanje i vlasišta razlikuje se

od osobe do osobe, vrat i čeljust ulaze u snimku u nedosljednoj mjeri ovisno o vidnome polju, a oči su svijetle, visokokontrastne strukture za koje bi se model lako mogao uhvatiti iako ne nose nikakvu informaciju o neurodegeneraciji. Uklanjanje toga tkiva ujedno znatno olakšava sljedeći korak, registraciju, jer se tada mozak poravnava s mozgom bez ometanja okolnom lubanjom.

Ekstrakcija mozga ima dugu povijest. Klasični su alati vođeni intenzitetom i geometrijom: primjerice, BET [13] iz paketa FSL [14] prilagođava deformabilnu plohu koja se širi do granice mozga, a sličnim se idejama koriste FreeSurfer [15] i AFNI [16]. Takve su metode brze, ali znaju biti krhke kad se kontrast ili vidno polje razlikuju od onih za koje su ugođene. Novija je generacija zasnovana na strojnom učenju, a u ovome je radu odabran SynthStrip [17] — neuronska mreža isporučena uz FreeSurfer, istrenirana na velikom skupu sintetičkih snimaka koje namjerno pokrivaju vrlo širok raspon kontrasta, rezolucija i anatomija. Budući da je tijekom učenja vidjela tako raznolike izglede, mreža je neuobičajeno robustna, što ju je i preporučilo za ovaj heterogeni skup podataka.

Umjesto instalacije cijeloga FreeSurfer okruženja, ovaj se korak izvodi pokretanjem službenoga Docker kontejnera sa SynthStripom. Za svaku se sesiju njezin direktorij montira kao ulaz, a izlazni kao izlaz, te se mreža pozove nad svakom snimkom, zapisujući snimku izdvojenoga mozga i pripadnu binarnu masku. Granica se maske pritom proširuje za jedan voksel (opcija --border 1) kako bi ekstrakcija radije zadržala tanki sloj kore nego ga odrezala; ostale su postavke ostavljene na zadanim vrijednostima jer se mreža ne ugađa po snimci. Načini na koje uklanjanje lubanje može zakazati — odrezan komadić kore ili zadržan dio ovojnice — suptilni su u brojevima, ali očiti oku, pa je kontrola kvalitete ovdje prvenstveno vizualna: maska se mozga preklapa preko izvorne snimke u trima ortogonalnim ravninama, odnosno granica se maske iscrtava kao crvena kontura preko anatomije (slika 3.4), čime svako curenje ili prekomjerno rezanje na površini mozga postaje odmah uočljivo.



Slika 3.4 Uklanjanje lubanje metodom SynthStrip. Lijevo: ulazna snimka cijele glave. U sredini: granica procijenjene maske mozga (crvena kontura) preklopljena preko anatomije. Desno: izdvojeni mozak.

3.5 Prostorna registracija

Do ove točke svaki mozak još uvijek živi u vlastitom prostoru: nalazi se na drukčijem položaju i pod drukčijim kutom u svakoj snimci, a mozgovi se međusobno razlikuju i ukupnom veličinom. Prostorna je registracija postupak pronalaženja geometrijske transformacije koja svaki pojedini mozak preslikava na zajednički referentni mozak, tako da nakon nje isti indeks voksela označava istu anatomsku lokaciju u svakoj snimci. To je vjerojatno najvažniji korak za to da konvolucijski model uopće može učiti preko subjekata: konvolucijska mreža dijeli svoje težine preko cijele slike i cijeloga skupa, a takvo dijeljenje težina ima smisla samo ako sto mjesto na slici znači ista anatomija u svakom primjeru.

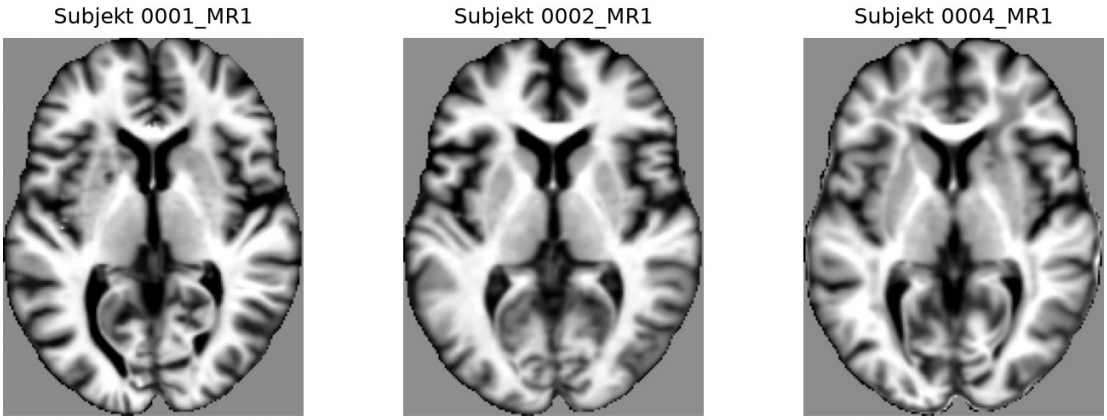
Zajednička je referenca predložak (engl. Template) — standardni mozak u standardnom koordinatnom sustavu. U ovome se radu koristi predložak MNI152NLin2009cAsym [18] pri izotropnoj rezoluciji od 1 mm, široko prihvaćeni MNI standard, i to u inačici samo s mozgom kako bi odgovarao snimkama bez lubanje. Predložak se dohvaća putem programskoga sučelja TemplateFlow [19].

Za poravnanje mozgova odabrana je metoda SyN (engl. Symmetric Normalization) iz programskoga paketa ANTs [20], koja se u nezavisnim usporedbama dosljedno pokazivala

među najboljima [21]. Njezina je zadaća svaki mozak mapirati na zajednički referentni mozak (predložak) tako da se poklope. Pritom SyN mozak glatko rasteže i sažima na pojedinim mjestima, ali nikad ne kida niti preklapa tkivo.

Poravnanje se ne radi odjednom, nego u tri koraka. Prvi korak mozak samo pomakne i zarotira na pravo mjesto, ne mijenjajući mu oblik. Drugi ga korak još ravnomjerno poveća ili smanji i blago rastegne, da se veličinom grubo podudari s predloškom. Tek treći korak lokalno rasteže pojedine dijelove kako bi se poklopile i sitne vijuge. Redoslijed je važan: prva su dva koraka brza i jeftina pa mozak grubo dovedu na mjesto i time trećem, sporom i osjetljivom koraku daju dobru polazišnu točku.

Svaki se od tih koraka, k tome, izvodi od grube prema sve finijoj razini, a koliko će se na pojedinoj razini truditi određeno je brojem dopuštenih pokušaja: za korak ravnomjernoga poravnanja do 2100, 1200, 1200 i 100 pokušaja kroz četiri razine, a za najfiniji korak do 80, 40 i 20 pokušaja kroz tri razine. Naposljetku se rezultat još obreže maskom mozga iz predloška, čime se uklanja tanki rub koji nastaje pri preračunavanju vrijednosti na novim položajima i inače se zna pojaviti na granici snimke.



Slika 3.5 Učinak registracije: isti aksijalni presjek u MNI prostoru za tri različita subjekta

Registracija je korak u kojem se događa najviše pogreški, a loše poravnana snimka modelu šteti više nego snimka koja uopće nedostaje jer mu daje krivu informaciju. Zato se za svaku registraciju bilježi nekoliko brojčanih pokazatelja kvalitete i provode automatske provjere.

Prvi pokazatelj mjeri koliko se snimka i predložak slažu po sadržaju, čak i kad im se svjetline razlikuju (uzajamna informacija, engl. Mutual Information, MI). ANTs ga vraća kao negativan broj koji treba biti što manji, pa je negativnija vrijednost bolja. Drugi pokazatelj mjeri koliko su dvije snimke međusobno slične, na ljestvici od −1 do 1, gdje viša vrijednost znači bolje poklapanje (normalizirana unakrsna korelacija, NCC). Treći pokazatelj prati mijenja li se negdje volumen tkiva na fizički nemoguć način — da se tkivo presavije preko sebe; ako bi do toga došlo, taj bi pokazatelj (determinanta Jacobijeve matrice) pao ispod nule. Bilježi se i koliko su se točke u prosjeku pomaknule, izraženo u milimetrima.

Promatrano preko svih 193 snimki, oba su se pokazatelja slaganja znatno poboljšala: uzajamna informacija u prosjeku s −0,272 na −0,605, a sličnost (NCC) s 0,160 na 0,755. To je velik i dosljedan napredak koji pokazuje da su mozgovi nakon registracije zaista blisko poravnati s predloškom. Pokazatelj promjene volumena u prosjeku je iznosio točno 1,000 i nigdje nije pao ispod nule, što znači da nigdje nije došlo do nemogućega presavijanja tkiva.

3.6 Normalizacija intenziteta i rezanje

Nakon registracije sve su snimke geometrijski poravnane, no njihovi su intenziteti i dalje na proizvoljnim, za pojedinu snimku specifičnim skalama, jer magnetska rezonancija nije kvantitativna metoda i apsolutna svjetlina voksela nema nepromjenjivo značenje preko snimaka. Konvolucijska mreža, međutim, očekuje ulaze na dosljednom brojčanom rasponu, a učenje biva bolje kada su ulazi centrirani i skalirani. Normalizacija intenziteta to rješava postavljajući svaku snimku na istu statističku osnovu. Uz to ovaj korak snimke reže na područje mozga, odbacujući velik prazni rub i tako štedeći memoriju i računanje.

U neuroslikanju je u uporabi nekoliko strategija normalizacije: skaliranje na fiksni raspon, usklađivanje histograma s referentnom snimkom te z-normalizacija, odnosno standardizacija na nultu srednju vrijednost i jediničnu varijancu. U ovome se radu koristi z-normalizacija, ali računata isključivo unutar maske mozga. Ograničenje na mozak pritom je ključno: kad bi se statistike računale nad cijelom snimkom, golema bi pozadina nultih vrijednosti prevladala, povukla srednju vrijednost prema nuli i stisnula standardnu devijaciju, čime bi se iskrivila standardizacija upravo onoga tkiva koje je važno.

Postupak čita svaku registriranu snimku, reorijentira je tako da se točno podudara s konvencijom osi predloška te primjenjuje tri operacije. Najprije se intenziteti unutar mozga odrezuju na 1. i 99. percentil, čime se uklanja utjecaj nekolicine ekstremnih izdvojenih voksela. Zatim se ti odrezani intenziteti standardiziraju na nultu srednju vrijednost i jediničnu varijancu, dok se vokselima izvan maske eksplicitno dodjeljuje vrijednost nula. Naposljetku se snimka reže na okvir maske mozga predloška, čime se dobiva nepromjenjiv izlazni oblik od 154 × 181 × 144 voksela pri rezoluciji od 1 mm, jednak za svaki subjekt jer je okvir definiran na zajedničkom predlošku. Rezanje uklanja otprilike polovicu rešetke predloška — gotovo samu pozadinu — i razmjerno tomu smanjuje memorijske i računske zahtjeve, a da se ne odbaci nimalo mozga.

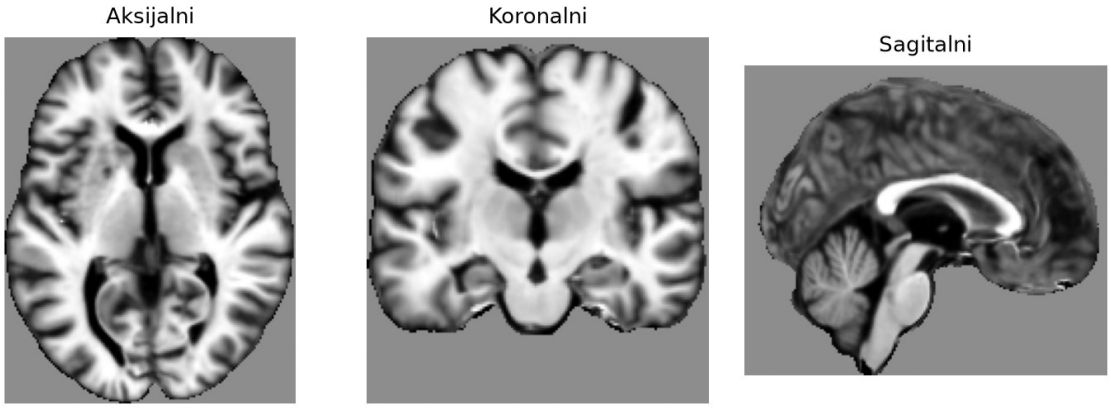
Budući da je cjevovod dug i da svaki korak ovisi o nepromjenjivim svojstvima prethodnoga, nad normaliziranim se snimkama, kao i na prethodnim koracima, provodi automatska provjera uspješnosti postupka. Za svaku se snimku bilježi: geometrija (oblik polja, razmak voksela, smjerna matrica i podudarnost s predloškom), valjanost (postojanje bilo kakvih NaN ili beskonačnih vrijednosti) te intenzitet, kako globalni tako i onaj unutar mozga. Za sve je konačne snimke srednja vrijednost unutar mozga bliska nuli, a standardna devijacija bliska jedinici — točno kako se i očekuje nakon z-normalizacije — te ni jedna snimka nije sadržavala nevaljane vrijednosti.

3.7 Usrednjavanje

Kao što je opisano u prethodnome poglavlju, svaka je sesija snimljena kao nekoliko ponovljenih MP-RAGE prolazaka. Budući da su svi prošli isti cjevovod — registrirani su na isti predložak i normalizirani na isti način — ti su prolasci sada poravnani voksel po voksel i na istoj skali intenziteta, pa se mogu jednostavno usrednjiti. Usrednjavanje ponovljenih snimki klasičan je način poboljšanja omjera signala i šuma (engl. Signal-to-Noise Ratio, SNR): podležeća je anatomija jednaka u svakom prolasku pa se pri zbrajanju pojačava, dok je šum slučajan i većinom se međusobno poništava.

Postupak za svaku sesiju učitava sve njezine snimke, usrednjuje ih voksel po vokselu i zapisuje jednu datoteku po sesiji. Time se dolazi do konačnoga skupa od 373 snimke na razini sesije — po jedne za svaku slikovnu sesiju — od kojih je svaka bez lubanje, korigirana za bias polje, registrirana u MNI prostor, standardiziranoga intenziteta, izrezana na jednoliku rešetku 154 ×

181 × 144 voksela i poboljšanoga omjera signala i šuma. Tri ortogonalna presjeka jedne takve konačne snimke prikazana su na slici 3.6.



Slika 3.6 Konačna snimka na razini sesije nakon usrednjavanja prolazaka, prikazana u trima ortogonalnim presjecima

4 IZRADA MODELA

Nad skupom od 373 predobrađene snimke izgrađen je model čiji je zadatak prepoznati pacijente kod kojih će bolest napredovati. Ovo poglavlje opisuje kako je model nastao: kako je problem predviđanja postavljen, koja je prednaučena mreža uzeta kao temelj, kako su slikovni i tablični podaci spojeni u jedinstvenu arhitekturu te kako je model učen i ocjenjivan.

4.1 Definicija zadatka

Prije bilo kakvoga učenja potrebno je precizno odrediti što se zapravo predviđa. Budući da je zbirka OASIS-2 longitudinalna, svaki je sudionik snimljen u više navrata, pa se za svakoga sudionika uzastopni posjeti povezuju u parove oblika trenutni → sljedeći posjet. Svaki takav par čini jedan primjer za učenje. Model pri tome uvijek vidi samo snimku i metapodatke trenutnoga posjeta, dok labela proizlazi iz sljedećega posjeta. Snimka i podaci sljedećega posjeta nikada se ne predaju modelu jer bi to značilo da model već ima pristup odgovoru, što bi dovelo do nerealno dobrih, ali bezvrijednih rezultata (tzv. curenje informacija, engl. data leakage). Iz istoga je razloga isključeno i obilježje kliničke skupine (engl. group), koje već sadrži konačnu dijagnozu sudionika.

Razmatraju se tri načina na koji se ishod sljedećega posjeta može izraziti kao ciljna varijabla, sažeta u Tablici 4.1. Prva varijabla, nazvana cdr3, predviđa CDR ocjenu sljedećega posjeta svrstanu u tri razreda. Druga, worsen, binarna je varijabla koja označava pogoršanje u stanju pacijenta u odnosu na prošli posjet, to jest je li CDR sljedećega posjeta viši od trenutnoga. Treća, convert, definirana je samo nad parovima koji počinju iz zdravoga stanja (trenutni CDR jednak nuli) i označava prelazak iz zdravlja u kognitivno oštećenje.

Kao glavna ciljna varijabla odabran je worsen. Trenutna CDR ocjena gotovo savršeno predviđa CDR ocjenu sljedećega posjeta (tko je danas zdrav, najvjerojatnije je zdrav i za godinu dana), pa bi varijabla cdr3 velikim dijelom bila pogodljiva pukim prepisivanjem trenutnoga stanja. Varijabla worsen mjeri samu promjenu i upravo je to ono u čemu bi MRI snimka trebala donijeti dodatnu vrijednost. Njezina je raspodjela, valja naglasiti, izrazito neuravnotežena: od ukupno 223 para, do pogoršanja dolazi u samo 31 (omjer približno 6:1), što je glavni izazov zadatka.

Tablica 4.1 Tri ciljne varijable razmatrane u radu.

Varijabla	Razredi
cdr3	3 (0; 0,5; ≥ 1)
worsen	2 (ne / da)
convert	2 (ne / da)

4.2 MedicalNet

Učenje duboke neuronske mreže od nule zahtijeva velik broj primjera, kojih u medicinskoj slikovnoj dijagnostici redovito nedostaje. Kao alternativa nameće se prijenosno učenje (engl. transfer learning). Umjesto da se kreće od slučajno postavljenih težina, polazi se od mreže koja je već naučena na velikoj zbirci sličnih podataka te je stoga već usvojila osnovne vizualne pojmove poput rubova, tekstura i oblika. Takvoj je mreži zatim potrebno mnogo manje primjera da se prilagodi novom, specifičnom zadatku.

Kao temelj slikovnoga dijela modela odabrana je rezidualna neuronska mreža (engl. Residual Network, ResNet) [22]. Rezidualne mreže koriste preskočne veze koje omogućuju da signal preskoči pojedine slojeve; time se izbjegava problem nestajućega gradijenta i omogućuje učenje vrlo dubokih mreža. Korišten je model dubine 10 (ResNet-10), namjerno najplića dostupna varijanta, jer manji broj parametara na ovako malom skupu podataka znači manju sklonost prenaučenju.

Gotove težine preuzete su iz projekta MedicalNet [4], koji nudi trodimenzionalne ResNet mreže prethodno naučene na velikoj i raznorodnoj zbirci 3D medicinskih snimaka. Za razliku od mreža naučenih na svakodnevnim fotografijama, ovdje su značajke naučene upravo na medicinskim snimkama, što ih čini osobito prikladnima za MRI snimke mozga. Iz preuzetoga modela zadržan je samo dio za izlučivanje značajki (koder), dok je izvorna izlazna glava za segmentaciju odbačena, a na njezino je mjesto dodano globalno usrednjavanje (engl. global average pooling) koje cijeli trodimenzionalni volumen sažima u jedan vektor od 512 brojeva. Taj vektor predstavlja sažeti, brojčani opis snimke koji dalje koristi ostatak modela.

Mreže iz projekta MedicalNet prednaučene su postupkom koji su autori nazvali Med3D: kombiniranjem osam javno dostupnih skupova trodimenzionalnih medicinskih snimaka

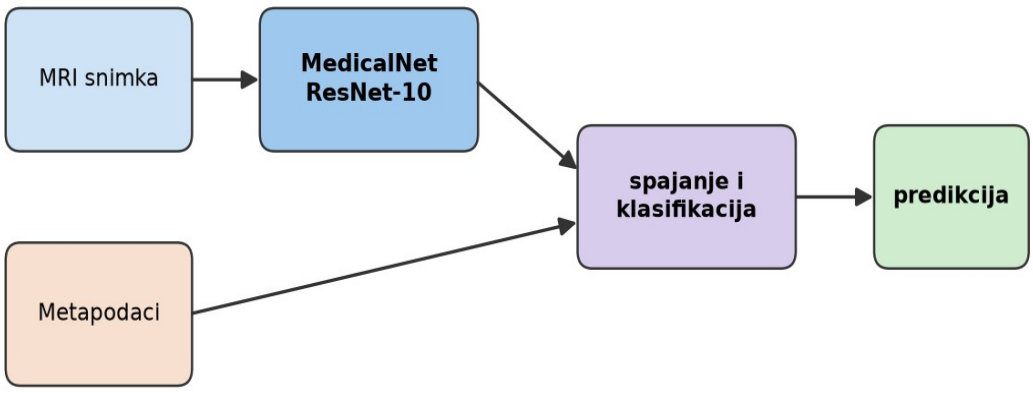
različitih organa (od snimaka mozga i srca do jetre i prostate) u jedinstven skup za učenje. Time je mreža bila izložena vrlo raznolikoj anatomiji, pa naučene značajke nisu vezane uz samo jednu vrstu snimke, nego hvataju opća svojstva ljudskoga tkiva na trodimenzionalnim snimkama.

Izvorni je zadatak prednaučenja bio segmentacija, to jest označavanje svakoga pojedinog voksela snimke. Kako bi se pri tome očuvala prostorna razlučivost, dublji slojevi mreže koriste takozvane proširene konvolucije (engl. dilated convolutions). Te su pojedinosti u modelu zadržane nepromijenjenima kako bi se preuzete težine mogle učitati bez odstupanja. Inačica dubine 10 koristi takozvani osnovni blok (engl. basic block) i daje izlazni vektor od 512 značajki, dok dublje varijante (ResNet-50 i veće) koriste složeniji blok i daju i do 2048 značajki; veći kapacitet na ovako malom skupu podataka samo bi povećao opasnost od prenaučenja.

Pri učitavanju je iz datoteke s težinama uklonjen prefiks koji potječe od učenja na više grafičkih procesora te su izostavljeni slojevi izvorne segmentacijske glave, čime je u koder uspješno preneseno svih 72 sloja težina. Tako pripremljen koder može se koristiti na dva načina: kao nepromjenjivi izlučivač značajki, pri čemu sve težine ostaju zamrznute, ili uz dodatno ugađanje posljednjih slojeva na podatke ovoga zadatka. Usporedba tih dviju strategija provedena je u sklopu rezultata.

4.3 Arhitektura modela

Model je zamišljen kao dvogranna mreža koja istodobno obrađuje dva izvora podataka — MRI snimku i metapodatke — te ih spaja u zajedničku odluku.



Slika 4.1 Shema arhitekture.

Slikovna grana kao ulaz ne uzima cijeli volumen, nego tanki aksijalni odsječak oblika 96 × 96 × 32. Time se računski trošak smanjuje približno tri puta uz očuvanje trodimenzionalnoga konteksta; budući da su sve snimke prethodno registrirane na zajednički predložak, isti fiksni odsječak kod svih sudionika pokriva istu anatomiju. Primjer takve ulazne snimke prikazan je u prethodnim poglavljima. Odsječak prolazi kroz već opisani ResNet-10 koder koji ga pretvara u vektor od 512 značajki, a taj se vektor potom kroz slikovnu glavu sažima na 128 dimenzija.

Tablična grana obrađuje šest odabranih metapodataka navedenih u Tablici 4.2. Obilježja geometrije snimke (eTIV, ASF), koja su međusobno gotovo savršeno korelirana i tek odražavaju veličinu glave, te socioekonomski status (bez signala i s mnogo nedostajućih vrijednosti), dob i redni broj posjeta namjerno su izostavljeni. Važno je istaknuti da je tablična grana namjerno oslabljena — koristi vrlo mali izlazni vektor (samo 8 dimenzija) uz pojačano izbacivanje (engl. dropout) — kako bi se spriječilo da šumoviti metapodaci pri spajanju nadvladaju ili razrijede vrjednije slikovne značajke.

Tablica 4.2 Prikaz tabličnih značajki korištenih u modelu

Značajka	**Opis**
cur_CDR	Trenutna CDR ocjena
MMSE	Rezultat Mini-Mental State Examination testa
nWBV	Normalizirani volumen cijeloga mozga
gap_days	Broj dana do sljedećega posjeta
EDUC	Broj godina obrazovanja
is_female	Spol (1 = žensko, 0 = muško)

Obje grane spajaju se na razini izlaza: vektor od 128 slikovnih i 8 tabličnih značajki povezuje se u jedinstveni vektor koji potom prolazi kroz klasifikacijsku glavu i daje konačnu predikciju. Dijelovi se mogu pokrenuti zasebno ili zajedno čime je omogućena izravna mjera doprinosa svakoga pojedinog izvora podataka. Dodatno se može odabrati i dubina ugađanja kodera: ugađa se ili samo posljednji rezidualni blok zajedno s glavama, ili se cijeli koder posve zamrzava i koristi isključivo kao nepromjenjivi izlučivač značajki. Usporedba tih izbora dio je rezultata iznesenih u petome poglavlju.

4.4 Postupak učenja i evaluacije

Kako bi se ubrzalo učenje, sve su snimke najprije jednokratno pretvorene u ulazni oblik (učitane, po potrebi izrezane i preuzorkovane na rešetku 96 × 96 × 32) i spremljene na disk, čime svaki kasniji eksperiment izbjegava ponovno sporo učitavanje. Tijekom učenja na snimke se primjenjuje blago nasumično proširenje podataka (engl. data augmentation) — zrcaljenje i dodavanje slaboga šuma — koje umjetno povećava raznolikost primjera i smanjuje prenaučenost.

Zbog male veličine skupa i izražene neuravnoteženosti razreda evaluacija korištena je ponovljena, stratificirana unakrsna validacija grupirana po subjektu (engl. StratifiedGroupKFold) [23]: podaci se dijele na 5 preklopa (engl. fold), a cijeli se postupak ponavlja 5 puta čime se dobiva ukupno 25 provjera. Ponavljanje je nužno jer je na ovako malom skupu jedan rezultat unakrsne validacije nepredvidiv. Grupiranje po subjektu je ključno: ono jamči da se nijedan pacijent ne pojavi istovremeno u skupu za učenje i u skupu za provjeru, što bi inače dovelo do nerealno dobrih rezultata. Stratifikacija pak osigurava da je rijetki pozitivni razred podjednako zastupljen u svakom preklopu.

Mreža se uči minimizacijom funkcije gubitka unakrsne entropije. Korišten je optimizator AdamW [24] uz kosinusno opadanje stope učenja, a učenje je provedeno na grafičkim procesorima platforme Kaggle uz automatsku mješovitu preciznost (engl. AMP) zbog brzine. Od svih epoha zadržava se ona s najboljim rezultatom na skupu za provjeru.

Za ocjenu uspješnosti odabrane su mjere prikladne za neuravnotežene podatke, kod kojih bi obična točnost bila zavaravajuća (model koji uvijek predviđa „nema pogoršanja" postigao bi visoku točnost, a bio bi beskoristan). Izvještavaju se uravnotežena točnost, makro-F1, površina ispod ROC krivulje (AUC) te površina ispod krivulje preciznost-odziv (PR-AUC). Uz srednju vrijednost i standardnu devijaciju po preklopima navodi se i 95-postotni interval pouzdanosti dobiven postupkom samopodizanja (engl. bootstrap).

Naposljetku, razlike među inačicama modela ne ocjenjuju se pukim uspoređivanjem srednjih vrijednosti, nego uparenim testovima značajnosti (Wilcoxonovim testom i Studentovim t-

testom) nad istim preklopima, jer razlika u prosjeku sama po sebi nije pouzdan nalaz dok je ne potvrdi statistički test.

5 REZULTATI

U ovome se poglavlju iznose i uspoređuju rezultati svih provedenih eksperimenata. Naglasak nije na jednom konačnom broju, nego na usporedbi različitih pristupa: ispituje se kako na uspješnost utječu izbor ciljne varijable (predviđanje samoga stanja, predviđanje pogoršanja te predviđanje konverzije iz zdravoga stanja), izbor izvora podataka (slika, metapodaci ili njihova fuzija), prostorna rezolucija ulaza, dubina ugađanja mreže te izrezivanje snimke na uže anatomsko područje. Svi su rezultati dobiveni ponovljenom unakrsnom validacijom (5 × 5 preklopa) opisanom u prethodnome poglavlju i navode se kao srednja vrijednost ± standardna devijacija po preklopima, a razlike među pristupima potkrijepljene su uparenim testovima značajnosti nad istim preklopima.

5.1 Referentne vrijednosti

Da bi se postignuti rezultati mogli ispravno protumačiti, najprije se utvrđuju referentne vrijednosti koje model mora nadmašiti. Najjednostavnija je takva referenca trivijalni model koji uvijek predviđa većinski razred, to jest „neće doći do pogoršanja”. Takav model postiže uravnoteženu točnost 0,500 (razina nasumičnoga pogađanja) i makro-F1 0,463.

Ovdje treba objasniti i zašto je odbačena prva, naizgled prirodna ciljna varijabla cdr3, kojom bi se izravno predviđala CDR ocjena sljedećega posjeta. Problem je u tome što se CDR ocjena između dvaju posjeta najčešće uopće ne mijenja, pa trivijalni model koji jednostavno ponovi trenutnu ocjenu kao predikciju za sljedeći posjet postiže vrlo visoku točnost. Drugim riječima, varijabla cdr3 daje varljivo dobre rezultate koji ne odražavaju nikakvo stvarno predviđanje. Upravo zato je težište prebačeno na varijablu worsen, koja mjeri samu promjenu stanja i na kojoj trivijalno prepisivanje ne pomaže.

Naposljetku, kao naučena (netrivijalna) referenca služi model koji koristi isključivo metapodatke. Za varijablu worsen taj model postiže uravnoteženu točnost tek 0,549, a njegov je AUC čak 0,466 — ispod razine nasumičnoga pogađanja.

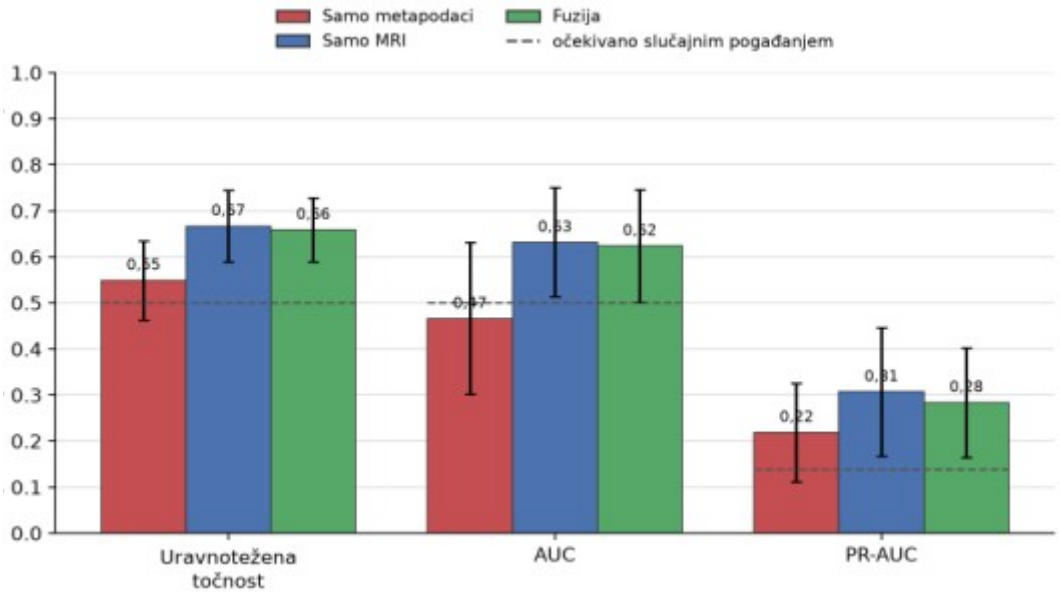
5.2 Usporedba modaliteta

Središnja usporedba rada temelji se na trima načinima rada modela nad osnovnom konfiguracijom (cijeli mozak, ulaz 96 × 96 × 32, ugađanje posljednjega bloka, ciljna varijabla

worsen): modela koji koristi samo metapodatke, modela koji koristi samo MRI snimku te modela koji oba izvora spaja fuzijom. Rezultati su prikazani u Tablici 5.1 i na Slici 5.1.

Tablica 5.1 Uspješnost triju načina rada za varijablu worsen

Način rada	**Uravn. točnost**	**Makro-F1**	**AUC**	**PR-AUC**
Samo metapodaci	0,549 ± 0,086	0,536	0,466	0,219
Samo MRI	0,667 ± 0,078	0,632	0,632	0,307
Fuzija	0,659 ± 0,069	0,623	0,624	0,284



Slika 5.1 Usporedba triju načina rada za varijablu worsen. Stupci prikazuju srednju vrijednost preko 25 preklopa, a crte pogreške standardnu devijaciju. Isprekidana linija označava vrijednost očekivanu pri slučajnom pogađanju (0,5 za uravnoteženu točnost i AUC, odnosno udio pozitivnih primjera za PR-AUC).

Model koji koristi samo MRI snimku jasno nadmašuje model temeljen na metapodacima, i to po svim mjerama. Uparena usporedba (Tablica 5.3) potvrđuje da je ta razlika statistički značajna: uravnotežena točnost viša je za 0,118 ($p = 0,0001$), a AUC za čak 0,166 ($p = 0,0010$). Ovo je glavni nalaz rada — predobrađena MRI snimka nosi stvaran prediktivni signal o budućem pogoršanju, dok dostupni metapodaci sami po sebi gotovo da i ne pomažu.

Da bi se vidjelo što ti brojevi znače u praksi, korisno je pogledati matricu slikovnoga modela, zbrojenu kroz svih 25 preklopa (Tablica 5.2).

Tablica 5.2 Matrica slikovnoga modela za varijablu worsen

	Predviđeno: stabilno	**Predviđeno: pogoršanje**
Stvarno: stabilno	825	135
Stvarno: pogoršanje	81	74

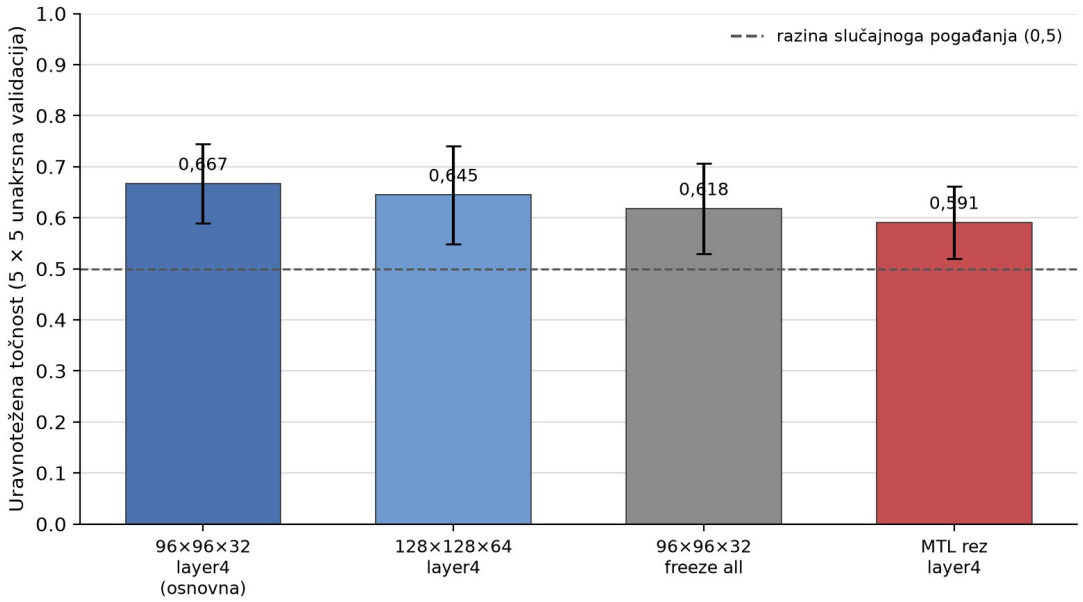
Budući da je svaki od 223 para ocijenjen u svih 5 ponavljanja, ukupno je provedeno 1115 procjena, od kojih se 155 odnosi na stvarna pogoršanja. Model je ispravno prepoznao 74 od tih 155 pogoršanja (odziv, engl. recall, od 48 %), dok je 81 pogoršanje promašio. Istodobno je 135 od 960 stabilnih slučajeva pogrešno označio kao buduće pogoršanje i poslao na daljnju obradu (lažne uzbune). Preciznost (engl. precision) za razred pogoršanja stoga iznosi tek 35 % — od svih koje model proglasi rizičnima, doista se pogorša otprilike trećina. Drugim riječima, na stvarnoj skupini od 31 pogoršanja model bi u prosjeku uhvatio njih oko 15, uz približno 27 lažnih uzbuna među 192 stabilna pacijenta. Takav je odnos očekivan kod ovako rijetkoga ishoda i pokazuje da model treba shvatiti kao alat za grubo probiranje (engl. screening), a ne kao samostalnu dijagnozu.

Tablica 5.3 Usporedba načina rada nad istih 25 preklopa (worsen).

Usporedba	**Δ uravn. toč.**	**p**	**Δ AUC**	**p**
MRI − metapodaci	+0,118	0,0001	+0,166	0,0010
Fuzija − MRI	−0,008	0,0707	−0,008	0,3011

5.3 Predviđanje pogoršanja

Budući da je worsen glavna ciljna varijabla, na njoj su ispitani i dodatni izbori pri izradi slikovnoga modela: prostorna rezolucija ulaza i dubina ugađanja prednaučene mreže. Sve su konfiguracije sažete na Slici 5.2 i u Tablici 5.4.



Slika 5.2 Usporedba slikovnoga modela (worsen) kroz četiri konfiguracije.

Kako bi se ispitalo pomaže li finija prostorna rezolucija, osnovni ulaz 96 × 96 × 32 uspoređen je s većim ulazom 128 × 128 × 64. Suprotno intuiciji, veća rezolucija nije poboljšala rezultat — uravnotežena točnost blago je pala s 0,667 na 0,645, uz veću varijancu i približno trostruko veći računski trošak. Razlog je u temeljnome ograničenju: uz samo 31 pozitivan primjer model je već na granici određenoj podacima, pa veći ulaz uglavnom povećava broj parametara i sklonost prenaučenju, umjesto da donese novu korisnu informaciju.

Tablica 5.4 Usporedba slikovnoga modela za varijablu worsen

Konfiguracija	**Uravn. točnost**	**AUC**
96 × 96 × 32, layer4 (osnovna)	0,667 ± 0,078	0,632
128 × 128 × 64, layer4	0,645 ± 0,096	—
96 × 96 × 32, freeze all	0,618 ± 0,088	0,631
MTL rez, layer4	0,591 ± 0,071	0,582

Drugi je ispitani izbor dubina ugađanja: ugađanje samo posljednjega rezidualnog bloka (layer4) naspram potpunoga zamrzavanja kodera. Ugađanje bloka layer4 daje višu uravnoteženu točnost (0,667 naspram 0,618), no zanimljivo je da je AUC praktički jednak (0,632 naspram 0,631). To

upućuje na zaključak da prednaučene značajke MedicalNeta već dobro rangiraju primjere (otuda jednak AUC), dok ugađanje posljednjega bloka prvenstveno pomiče radnu točku, to jest prag odlučivanja, prema specifičnostima moždanih snimaka, čime se popravlja uravnotežena točnost. Stoga je ugađanje bloka layer4 zadržano kao najbolji ukupni izbor.

5.4 Predviđanje konverzije

Posebno je zanimljiva ciljna varijabla convert, koja je zapravo varijanta varijable worsen ograničena samo na one parove koji počinju iz zdravoga stanja (trenutni CDR jednak nuli). Ona postavlja klinički najčišće pitanje: tko će od dosad zdravih osoba razviti kognitivno oštećenje? Time se, međutim, broj prikladnih primjera dodatno smanjuje — na samo 133 para, od kojih je 15 pozitivnih.

I na ovoj, težoj formulaciji slikovni model nadmašuje metapodatke: postiže uravnoteženu točnost 0,739 naspram 0,599, što je značajna razlika (+0,140, p = 0,011). Visoka uravnotežena točnost ohrabruje, no treba je tumačiti s velikim oprezom jer je interval pouzdanosti vrlo širok (± 0,164) — izravna posljedica vrlo malenoga broja pozitivnih primjera. Zbog toga se taj rezultat ne smije izravno uspoređivati s rezultatima za varijablu worsen. Rezultati su navedeni u Tablici 5.5.

Tablica 5.5 Uspješnost za ciljnu varijablu convert

Način rada	**Uravn. točnost**	**Makro-F1**	**AUC**
Samo metapodaci	0,599 ± 0,181	0,532	0,582
Samo MRI	0,739 ± 0,164	0,690	0,631

Da bi se sagledalo stvarno ponašanje modela, i ovdje je korisno pogledati matricu zabune slikovnoga modela zbrojenu kroz svih 25 preklopa (Tablica 5.6). Od 75 stvarnih konverzija (15 pacijenata ocijenjenih u 5 ponavljanja) model je ispravno prepoznao njih 32, što odgovara odzivu od 43 %; preostalih 43 konverzija je promašio. Među 590 procjena zdravih osoba njih je 54 pogrešno uputio na daljnju obradu, dok je 536 ispravno ostavio bez uzbune (specifičnost 91 %). Preciznost za razred konverzije iznosi 37 %. Prevedeno na stvarnu kohortu, model bi u prosjeku po jednom prolasku prepoznao otprilike 6 od 15 budućih konverzija uz približno 11 lažnih uzbuna među 118 zdravih osoba.

Tablica 5.6 Matrica zabune slikovnoga modela za varijablu convert

	Predviđeno: zdrav	**Predviđeno: konverzija**
Stvarno: zdrav	536	54
Stvarno: konverzija	43	32

5.5 Utjecaj anatomskog područja

Posljednji ispitani pristup tiče se anatomskoga područja koje se predaje modelu. Budući da je medijalni temporalni režanj (osobito hipokampus) područje koje Alzheimerova bolest najranije zahvaća [25], [26], postavljena je hipoteza da bi izrezivanje ulaza upravo na tu regiju usmjerilo model na najinformativnije tkivo i tako poboljšalo rezultat. Definiran je fiksni okvir izrezivanja (zadan udjelima svake osi i vizualno provjeren na snimkama) te je slikovni model ponovno učen samo na tako izrezanim volumenima.

Rezultat je suprotan očekivanju i predstavlja vrijedan negativan nalaz: izrezivanje je značajno smanjilo uspješnost, s uravnotežene točnosti 0,667 na 0,591 (razlika −0,076, p = 0,0007), kako pokazuje i crveni stupac na Slici 5.2. Nudi se nekoliko objašnjenja. Prvo, model po svemu sudeći koristi i globalni kontekst — proširenje moždanih klijetki i opću atrofiju mozga — koji se izrezivanjem na usku regiju gubi. Drugo, fiksni okvir definiran udjelima osi tek je približan i ne mora dosljedno obuhvatiti hipokampus u svakom subjektu. Treće, koder je prednaučen na cijelim organima, pa je usko izrezana snimka udaljenija od domene prednaučenja, čime se gubi dio prednosti prijenosnog učenja. Zaključno, na ovome skupu cjeloviti mozak nosi više korisne informacije od anatomski usmjerenoga isječka.

Sveukupno, usporedba pristupa daje dosljednu sliku. Najbolju uspješnost postiže najjednostavnija konfiguracija — cijeli mozak pri rezoluciji 96 × 96 × 32 uz ugađanje bloka layer4 — dok niti veća rezolucija, niti potpuno zamrzavanje, niti anatomsko izrezivanje, niti fuzija s metapodacima ne donose poboljšanje, a izrezivanje čak značajno šteti. To snažno upućuje na zaključak da je sustav dosegnuo granicu određenu količinom podataka (31 pozitivan primjer), a ne kapacitetom modela.

6 ZAKLJUČAK

U ovome je radu istražena primjena metoda strojnoga učenja za predviđanje progresije Alzheimerove bolesti na temelju MRI snimaka i pripadajućih metapodataka iz javno dostupnoga skupa OASIS-2. Provedena je cjelovita predobrada snimaka — od pretvorbe formata i ujednačavanja orijentacije, preko korekcije bias polja, uklanjanja lubanje, prostorne registracije i normalizacije intenziteta, do usrednjavanja ponovljenih snimaka — kako bi se uklonila smetajuća varijacija i snimke učinile međusobno usporedivima. Nad tako pripremljenim podacima izgrađen je model koji prijenosnim učenjem koristi prednaučenu trodimenzionalnu mrežu MedicalNet ResNet-10 i po potrebi je spaja s tabličnim metapodacima.

Glavni je nalaz rada da predobrađena MRI snimka nosi stvaran prediktivni signal o budućem pogoršanju bolesti. Slikovni je model u svim ispitanim postavkama nadmašio model koji se oslanja isključivo na metapodatke, i to statistički značajno (za ciljnu varijablu pogoršanja uravnotežena točnost 0,667 naspram 0,549, $p = 0{,}0001$). To je važno jer pokazuje da sami klinički i demografski podaci, koji opisuju zatečenu težinu bolesti, gotovo da i ne govore hoće li ona napredovati, dok snimka mozga taj signal ipak sadrži. Time je ostvaren temeljni cilj rada.

Istodobno, postignuti su rezultati šaroliki i umjereni, a njihovo objašnjenje leži u samim podacima. Skup OASIS-2 za ovaj je zadatak malen i izrazito neuravnotežen: među 223 para uzastopnih posjeta tek je 31 slučaj pogoršanja. Posljedice su toga vidljive kroz cijeli rad — široki intervali pouzdanosti, velika promjenjivost rezultata od preklopa do preklopa te skromna preciznost i odziv pri stvarnom razvrstavanju. Pokazalo se i da povećanje rezolucije ulaza, dublje ugađanje mreže te spajanje s metapodacima ne donose poboljšanje, a izrezivanje snimke na medijalni temporalni režanj uspješnost čak značajno smanjuje. Takva dosljedna slika snažno upućuje na zaključak da je sustav dosegnuo granicu određenu količinom podataka, a ne kapacitetom modela: jednostavnija rješenja jednako su dobra kao i složenija jer naprosto nema dovoljno primjera iz kojih bi složeniji model mogao naučiti više.

Te činjenice ujedno predstavljaju i glavna ograničenja rada. Mali i neuravnotežen skup podataka, oslanjanje na jedan jedini izvor snimaka te izostanak neovisne, vanjske provjere znače da se postignuti brojevi ne smiju shvatiti kao konačna mjera uspješnosti, nego kao pokazatelj da signal postoji i da ga je vrijedno dalje istraživati.

Posebno treba naglasiti da model razvijen u ovome radu nije namijenjen za uporabu na stvarnim pacijentima niti za postavljanje dijagnoze. Postignuta razina uspješnosti, uz velik udio promašenih slučajeva i lažnih uzbuna, primjerena je najviše kao gruba ilustracija istraživačke ideje, a ne kao klinički alat. Svaka stvarna primjena u medicini zahtijevala bi neusporedivo veći i raznovrsniji skup podataka, neovisnu validaciju na više ustanova te temeljitu kliničku i etičku procjenu.

Kao smjernice za budući rad nameću se ponajprije proširenje skupa podataka, čime bi se izravno ublažilo ključno ograničenje. Vrijedno bi bilo provesti i vanjsku validaciju modela na podacima iz druge ustanove, istražiti naprednije načine spajanja slikovnih i tabličnih značajki te primijeniti metode tumačenja predikcija, kako bi se provjerilo oslanja li se model na anatomski smislena područja.

LITERATURA

[1] Dementia. World Health Organization 2025. https://www.who.int/news-room/fact-sheets/detail/dementia (accessed June 26, 2026).

[2] Jack CR, Knopman DS, Jagust WJ i dr. Tracking Pathophysiological Processes in Alzheimer's Disease: An Updated Hypothetical Model of Dynamic Biomarkers. The Lancet Neurology 2013.

[3] Litjens G, Kooi T, Bejnordi BE i dr. A Survey on Deep Learning in Medical Image Analysis. Medical Image Analysis 2017.

[4] Chen S, Ma K, Zheng Y. Med3D: Transfer Learning for 3D Medical Image Analysis 2019.

[5] Marcus DS, Fotenos AF, Csernansky JG i dr. Open Access Series of Imaging Studies: Longitudinal MRI Data in Nondemented and Demented Older Adults. Journal of Cognitive Neuroscience 2010.

[6] Folstein MF, Folstein SE, McHugh PR. "Mini-Mental State": A Practical Method for Grading the Cognitive State of Patients for the Clinician. Journal of Psychiatric Research 1975.

[7] Morris JC. The Clinical Dementia Rating (CDR): Current Version and Scoring Rules. Neurology 1993.

[8] Brett M, Markiewicz CJ, Hanke M i dr. NiBabel: Access a Cacophony of Neuro-Imaging File Formats. Zenodo 2020.

[9] Sled JG, Zijdenbos AP, Evans AC. A Nonparametric Method for Automatic Correction of Intensity Nonuniformity in MRI Data. IEEE Transactions on Medical Imaging 1998.

[10] Tustison NJ, Avants BB, Cook PA i dr. N4ITK: Improved N3 Bias Correction. IEEE Transactions on Medical Imaging 2010.

[11] Lowekamp BC, Chen DT, Ibáñez L i dr. The Design of SimpleITK. Frontiers in Neuroinformatics 2013.

[12] Li CH, Lee CK. Minimum Cross Entropy Thresholding. Pattern Recognition 1993.

[13] Smith SM. Fast Robust Automated Brain Extraction. Human Brain Mapping 2002.

[14] Jenkinson M, Beckmann CF, Behrens TEJ i dr. FSL. NeuroImage 2012.

[15] Fischl B. FreeSurfer. NeuroImage 2012.

[16] Cox RW. AFNI: Software for Analysis and Visualization of Functional Magnetic Resonance Neuroimages. Computers and Biomedical Research 1996.

[17] Hoopes A, Mora JS, Dalca AV i dr. SynthStrip: Skull-Stripping for Any Brain Image. NeuroImage 2022.

[18] Fonov VS, Evans AC, Botteron K i dr. Unbiased Average Age-Appropriate Atlases for Pediatric Studies. NeuroImage 2011.

[19] Ciric R, Thompson WH, Lorenz R i dr. TemplateFlow: FAIR-Sharing of Multi-Scale, Multi-Species Brain Models. Nature Methods 2022.

[20] Avants BB, Epstein CL, Grossman M i dr. Symmetric Diffeomorphic Image Registration with Cross-Correlation: Evaluating Automated Labeling of Elderly and Neurodegenerative Brain. Medical Image Analysis 2008.

[21] Klein A, Andersson J, Ardekani BA i dr. Evaluation of 14 Nonlinear Deformation Algorithms Applied to Human Brain MRI Registration. NeuroImage 2009.

[22] He K, Zhang X, Ren S i dr. Deep Residual Learning for Image Recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR); 2016.

[23] Pedregosa F, Varoquaux G, Gramfort A i dr. Scikit-Learn: Machine Learning in Python. Journal of Machine Learning Research 2011.

[24] Loshchilov I, Hutter F. Decoupled Weight Decay Regularization. In International Conference on Learning Representations (ICLR); 2019.

[25] Braak H, Braak E. Neuropathological Stageing of Alzheimer-Related Changes. Acta Neuropathologica 1991.

[26] Frisoni GB, Fox NC, Jack CR i dr. The Clinical Use of Structural MRI in Alzheimer Disease. Nature Reviews Neurology 2010.

POPIS OZNAKA I KRATICA

3D – three-dimensional

AFNI – Analysis of Functional NeuroImages

AMP – Automatic Mixed Precision

ANTs – Advanced Normalization Tools

ASF – Atlas Scaling Factor

AUC – Area Under the Curve

BET – Brain Extraction Tool

CDR – Clinical Dementia Rating

CNN – Convolutional Neural Network

CV – Coefficient of Variation

EDUC – Education (years of education)

eTIV – estimated Total Intracranial Volume

F1 – F1 score (harmonic mean of precision and recall)

FSL – FMRIB Software Library

MedicalNet – pretrained 3D medical network (Med3D project)

MI – Mutual Information

MMSE – Mini-Mental State Examination

MNI – Montreal Neurological Institute

MP-RAGE – Magnetization Prepared Rapid Gradient-Echo

MRI – Magnetic Resonance Imaging

MTL – Medial Temporal Lobe

N3 – Nonparametric Nonuniform intensity Normalization

N4 – N4ITK bias field correction

NCC – Normalized Cross-Correlation

NIfTI – Neuroimaging Informatics Technology Initiative

nWBV – normalized Whole Brain Volume

OASIS – Open Access Series of Imaging Studies

PR-AUC – Precision-Recall Area Under the Curve

QC – Quality Control

RAS – Right-Anterior-Superior (orientation convention)

ResNet – Residual Network

ROC – Receiver Operating Characteristic

SD – Standard Deviation

SES – Socioeconomic Status

SNR – Signal-to-Noise Ratio

SyN – Symmetric Normalization

SAŽETAK

U ovome je radu istražena primjena metoda strojnoga učenja za predviđanje progresije Alzheimerove bolesti na temelju strukturnih MRI snimaka mozga i pripadajućih demografsko-kliničkih metapodataka iz javno dostupnoga longitudinalnog skupa OASIS-2. Najprije je provedena cjelovita predobrada snimaka — pretvorba formata i ujednačavanje orijentacije, korekcija bias polja, uklanjanje lubanje, prostorna registracija, normalizacija intenziteta te usrednjavanje ponovljenih snimaka — kako bi se uklonila smetajuća varijacija. Nad tako pripremljenim podacima izgrađen je model koji prijenosnim učenjem koristi prednaučenu trodimenzionalnu mrežu MedicalNet ResNet-10 i po potrebi je spaja s tabličnim metapodacima. Zadatak je postavljen kao predviđanje pogoršanja stanja pri sljedećem posjetu, a model je ocijenjen ponovljenom unakrsnom validacijom grupiranom po subjektu uz intervale pouzdanosti i uparene testove značajnosti. Glavni je nalaz da MRI snimka nosi stvaran prediktivni signal te statistički značajno nadmašuje model temeljen isključivo na metapodacima. Zbog maloga i izrazito neuravnoteženog skupa podataka rezultati su umjereni i promjenjivi, pa razvijeni model nije namijenjen kliničkoj uporabi, nego predstavlja metodološki strogu i ponovljivu osnovu za daljnja istraživanja.

Ključne riječi: Alzheimerova bolest; magnetska rezonancija; duboko učenje; prijenosno učenje; OASIS-2

SUMMARY

TITLE:Application of Machine Learning Methods on MRI Images for Predicting the Progression of Alzheimer's Disease

This thesis investigates the application of machine learning methods for predicting the progression of Alzheimer's disease from structural brain MRI scans and the accompanying demographic and clinical metadata of the publicly available longitudinal OASIS-2 dataset. First, a complete image preprocessing pipeline is carried out — format conversion and orientation standardization, bias field correction, skull stripping, spatial registration, intensity normalization, and averaging of repeated scans — in order to remove confounding variation. On the prepared data, a model is built that uses transfer learning with the pretrained three-dimensional MedicalNet ResNet-10 network and optionally fuses it with the tabular metadata. The task is formulated as predicting whether the condition will worsen at the next visit, and the model is evaluated using repeated subject-grouped cross-validation with confidence intervals and paired significance tests. The main finding is that the MRI scan carries a genuine predictive signal and significantly outperforms a model based solely on metadata. Due to the small and highly imbalanced dataset, the results are modest and variable, so the developed model is not intended for clinical use but rather serves as a methodologically rigorous and reproducible basis for further research.

Keywords: Alzheimer's disease; magnetic resonance imaging; deep learning; transfer learning; OASIS-2